## Składowanie danych w systemach Big Data Testy poprawności działania rozwiązania

Kacper Skonieczka, 313505

Grzegorz Zakrzewski, 313555

10 stycznia 2024

Nr	Co jest testowane?	W jaki sposób?	Oczekiwany wynik	Potwierdzenie
1	Sprawdzenie procesu składowania plików .parquet z cenami energii na daną godzinę z ENTSOE Transparency Platform	Wykonanie odpowiednich flow w Apache NiFi i sprawdzenie zawartości na HDFS	Widoczne wśród plików takie, które zawierają datę i godzinę "2024-01-08 13" w nazwie	<pre>vagrant@nodel:~\$ hdfs dfs -ls /user/project/germany_prices/   tail -n 5 SLF4U: Class path contains multiple SLF4J bindings. SLF4U: Found binding in [jar:file:/usr/local/hadoop-2.7.6/share/hadoop/common/lib/slf4j-log4j12-1.7.10.jar!/c SLF4U: Found binding in [jar:file:/usr/local/apache-tez-0.9.1-bin/lib/slf4j-log4j12-1.7.10.jar!/crg/slf4j/imp SLF4U: See http://www.slf4j.org/codes.htmlfmultiple bindings for an explanation. SLF4U: Rottual binding is of type [org.slf4j.impl.Log4jlogegrefactory] drwxr=xr=x - root supergroup 0 2024-01-08 13:40 /user/project/germany prices/prices_2024-01-08 1 drwxr=xr=x - root supergroup 0 2024-01-08 13:40 /user/project/germany_prices/prices_2024-01-08 1: drwxr=xr=x - root supergroup 0 2024-01-08 13:40 /user/project/germany_prices/prices_2024-01-08 1: drwxr=xr=x - root supergroup 0 2024-01-08 13:40 /user/project/germany_prices/prices_2024-01-08 1: drwxr=xr=x - root supergroup 0 2024-01-08 13:40 /user/project/germany_prices/prices_2024-01-08 1: drwxr=xr=x - root supergroup 0 2024-01-08 13:40 /user/project/germany_prices/prices_2024-01-08 1: drwxr=xr=x - root supergroup 0 2024-01-08 13:40 /user/project/germany_prices/prices_2024-01-08 1: drwxr=xr=x - root supergroup 0 2024-01-08 13:40 /user/project/germany_prices/prices_2024-01-08 1: drwxr=xr=x - root supergroup 0 2024-01-08 13:40 /user/project/germany_prices/prices_2024-01-08 1:</pre>
2	Sprawdzenie procesu składanie plików parquet z ilością energii wiatrowej na daną godzinę z ENT-SOE Transparency Platform	Wykonanie odpowiednich flow w Apache NiFi i sprawdzenie zawartości w Apache HBase	Widoczne rekordy z time- stamp z dnia 2024-01-08 sprzed godziny 14	hbase(main):016:0> scan 'germany_prices', (LIMIT => 5, REVERSED => true)  COLUMN*CELL  2 0204-01-07723:00Z  2 0204-01-06723:00Z
3	Sprawdzenie procesu zapi- sywania w Apache HBase najnowszych danych o ce- nach energii w Niemczech	Wykonanie odpowiednich flow w Apache NiFi i sprawdzenie zawartości na HDFS	Widoczne wsród plików takie, które zawierają da- tetime "2024-01-08 13" w nazwie	<pre>vagrant@nodel:~\$ hdfs dfs -ls /user/project/germany_prices/   tail -n 5 SIE44: Class path contains multiple SIE4J bindings SIE44: Found binding in [jar:file:/usr/local/hadoop-2.7.6/share/hadoop/common/lib/sIf4j-log4j12-1.7.10.jar!/c SIE40: Found binding in [jar:file:/usr/local/apache-tez-0.9.1-bin/lib/sIE4j-log4j12-1.7.10.jar!/crg/sIE4j/imp SIE40: See http://www.sIE4j.org/codes.html#multiple bindings for an explanation. SIE40: Actual binding is of type [org.sIE4j.impl.log4j10zgerEactory] drwxr-xr-x - root supergroup</pre>

4	Sprawdzenie procesu zapi- sywania w Apache HBa- se najnowszych danych o energii wiatrowej w Niem- czech	Wykonanie odpowiednich flow w Apache NiFi i sprawdzenie zawartości w Apache HBase	Widoczne wsród danych, rokordy z timestamp z dnia 2024-01-08 sprzed go- dziny 14	hbase(main):001:0> scan 'windOffShore', (LIMIT => 5, REVERSED => true)  ROW  COLUMN-CELL  9 2024-01-08723:00C  9 2024-01-07723:00C  0 0 unmn-cf:position, timestamp=2024-01-08713:56:07.068, value=2024-01-08 13  9 2024-01-07723:00C  0 0 unmn-cf:position, timestamp=2024-01-08713:56:07.068, value=2024-01-08 13  9 2024-01-07723:00C  0 0 unmn-cf:position, timestamp=2024-01-08713:56:07.068, value=2024-01-08 13  9 2024-01-07723:00C  0 0 unmn-cf:position = 0.00C  0 0
5	Sprawdzenie dostępności z Apache Spark plików pa- rquet z cenami energii na daną godzinę z ENTSOE Transparency Platform	Połączenie się z HDFS za pomocą odpowiedniej ścieżki i wyświetlenie czę- ści zawartości	Tabela jest zapełniona danymi o cenach energii	prices_da.show()    position price_amount    start_date    row_id    end_date publication_date      1
6	Sprawdzenie dostępności z Apache Spark plików pa- rquet z ilością energii wia- trowej na daną godzinę z ENTSOE Transparency Platform	Połączenie się z HDFS za pomocą odpowiedniej ścieżki i wyświetlenie czę- ści zawartości	Tabela jest zapełniona danymi o energii z wiatru	position quantity  start_date  row_id  end_date publication_date

7	Sprawdzenie, czy pliki GRIB2 z prognozami meteorologicznymi GEFS są prawidłowo pobierane do systemu plików HDFS	Uruchomienie procesorów Apache Nifi odpowiedzial- nych za pobieranie pliku i sprawdzenie zawartości HDFS	W HDFS w katalogu gefs/raw znajduje się po- brany plik GRIB2	<pre>vagrant@nodel:~\$ hadoop fs -ls /user/bigdataproject/gefs/raw SLF40: Class path contains multiple SLF4J bindings. SLF40: Found binding in [jar:file:/usr/local/hadoop-2.7.6/share/hadoop/common/lib/slf4j-log4j12-1.7.10.jar:/org/s SLF40: Found binding in [jar:file:/usr/local/apache-tez-0.9.i-bin/lib/slf4j-log4j12-1.7.10.jar:/org/slf4j/impl/St SLF40: See http://www.slf4j.org/codes.html#multiple bindings for an explanation. SLF40: Actual binding is of type [org.slf4j.impl.Log4jLoggerFactory] Found 1 items -rwr-r</pre>
8	Sprawdzenie, czy surowe pliki GRIB2 sa prawidło- wo konwertowane do pli- ków CSV	Uruchomienie procesora Apache Nifi odpowiedzial- nego za konwersję plików GRIB2 do formatu CSV i sprawdzenie katalogu w HDFS	W HDFS w katalogu gefs znajduje się przekonwer- towany plik CSV	<pre>vagrant@nodel:~/bigdataproject\$ hadoop fs -ls /user/bigdataproject/gefs SLF40: Class path contains multiple SLF40 bindings. SLF40: Found binding in [jar:file:/usr/local/hadoop-2.7.6/share/hadoop/common/lib/slf4j-log4j12-1.7.10.jar SLF40: Found binding in [jar:file:/usr/local/apache-tez-0.9.1-bin/lib/slf4j-log4j12-1.7.10.jar!/org/slf4j/ SLF40: See http://www.slf4j.org/codes.html#multiple_bindings for an explanation. SLF40: Actual binding is of type [org.slf4j.impl.Log4jLoggerFactory] Found 2 items -rw-rr- 1 root supergroup 53614 2024-01-07 21:45 /user/bigdataproject/gefs/gefs_20240107.csv</pre>
9	Sprawdzenie, czy dane z plików CSV są prawidło- wo wstawiane do tabeli Apache Hive	Uruchomienie procesorów Apache Nifi odpowiedzial- nych za wstawienie zawar- tości pliku CSV do tabeli i sprawdzenie zawartości tej tabeli	W tabeli Apache Hive znajdują się dane z pliku CSV	hive> select * from gefs where time = '2024-01-07' limit 5; OK  40.0 0.0 2024-01-07 00:00:00.0 2024-01-14 00:00:00.0 0.86 -0.69 40.0 0.5 2024-01-07 00:00:00.0 2024-01-14 00:00:00.0 1.15 0.12 40.0 1.0 2024-01-07 00:00:00.0 2024-01-14 00:00:00.0 2.1 1.4 40.0 1.5 2024-01-07 00:00:00.0 2024-01-14 00:00:00.0 3.08 2.17 40.0 2.0 2024-01-07 00:00:00.0 2024-01-14 00:00:00.0 3.88 2.57 5 rows selected (0.367 seconds) hive>
10	Sprawdzenie, czy dane z tabeli Apache Hive są pra- widłowo agregowane do tabeli Apache HBase	Uruchomienie procesorów Apache Nifi odpowiedzial- nych za agregację najnow- szych danych z tabeli Apa- che Hive i sprawdzenie za- wartości docelowej tabeli Apache HBase	W tabeli Apache HBase znajdują się zagregowane dane	hbase(main):047:0* scan 'gefe_agg'  R08  COLMN+CELL  COLUMN+CELL  COLUMN-CELL  COLU

11	Sprawdzenie, czy tabela Apache Hive z danymi GEFS przed agregacją jest dostępna z poziomu Apa- che Spark	Połączenie się z tabelą Apache Hive z użyciem odpowiedniego polecenia SQL w Apache Spark	Tabela jest dostępna i zawiera odpowiednie dane meteorologiczne	spark.sql("select * from gefs where latitude is not null;").show(n=10)  +
12	Sprawdzenie, czy tabela Apache HBase z danymi GEFS po agregacji jest dostępna z poziomu war- stwy analitycznej	Połączenie się z tabe- lą Apache HBase z uży- ciem dedykowanej biblio- teki happybase i spraw- dzenie zawartości rekordu dla odpowiedniego klucza	Są zwracane odpowiednie, zagregowane dane dla za- danego klucza	<pre>connection = happybase.Connection("localhost")  table = connection.table('gefs_agg') table.row(b"20231201")  {b'agg:u10_avg_north': b'-1.4940259740259734',    b'agg:u10_avg_south': b'-0.22376190476190475',    b'agg:u10_avg_total': b'-0.8891383219954643',    b'agg:v10_avg_north': b'1.9530735930735934',    b'agg:v10_avg_south': b'1.195142857142857',    b'agg:v10_avg_total': b'1.5921541950113374'}</pre>